

UNIVERSIDAD AUTÓNOMA DE MADRID

ESCUELA POLITÉCNICA SUPERIOR



# Evaluación de Bases de Datos Públicas EEG en la Escucha de Música

Informe Final

Máster Universitario en Ingeniería Informática

Curso 2024/2025

Autor: Alexandru Marius Platon

Tutor: Fabiano Baroni

Fecha de entrega: 23 de mayo de 2025



# Índice

|                |                                    |           |
|----------------|------------------------------------|-----------|
| <b>1</b>       | <b>Introducción</b>                | <b>1</b>  |
| 1.1            | Antecedentes . . . . .             | 1         |
| 1.2            | Motivación . . . . .               | 1         |
| 1.3            | Objetivos . . . . .                | 1         |
| <b>2</b>       | <b>Estado del Arte</b>             | <b>2</b>  |
| 2.1            | Sobre EEG . . . . .                | 2         |
| 2.2            | Música como estímulo . . . . .     | 4         |
| 2.3            | Calidad en EEG . . . . .           | 5         |
| 2.4            | Herramientas de análisis . . . . . | 6         |
| <b>3</b>       | <b>Bases de Datos Analizadas</b>   | <b>8</b>  |
| 3.1            | dsMUSING . . . . .                 | 8         |
| 3.2            | dsDRYAD . . . . .                  | 8         |
| 3.3            | dsNMEDE . . . . .                  | 9         |
| 3.4            | dsAUTh . . . . .                   | 9         |
| 3.5            | dsRIUMA . . . . .                  | 9         |
| <b>4</b>       | <b>Metodología</b>                 | <b>10</b> |
| 4.1            | Conversión de los datos . . . . .  | 10        |
| 4.2            | Ánalisis de Calidad . . . . .      | 12        |
| <b>5</b>       | <b>Resultados</b>                  | <b>17</b> |
| <b>6</b>       | <b>Conclusiones</b>                | <b>18</b> |
| <b>Anexo A</b> |                                    | <b>22</b> |
| <b>Anexo B</b> |                                    | <b>22</b> |

## **1. Introducción**

### **1.1. Antecedentes**

En el campo de la neurociencia, métodos no invasivos como el Electroencefalograma (EEG) son ampliamente usados en el ámbito de la investigación para registrar en tiempo real la actividad cerebral ante distintos estímulos. Uno de los más empleados en la actualidad es la música, ya que permite observar patrones específicos de activación cerebral. Estos patrones pueden variar tanto en función de las propiedades auditivas de la pieza musical, como su contenido melódico, armónico o rítmico, así como por factores subjetivos como la familiaridad o el disfrute [1, 2].

No obstante, la obtención de datos EEG suele ser un procedimiento costoso, que requiere contar con equipos y materiales especializados, un protocolo experimental bien definido y un grupo amplio de sujetos. Por ello, es común la creación de bases de datos públicas que recojan los registros de experimentos previamente realizados, con el objetivo de facilitar la reutilización de los mismos por parte de otros investigadores y fomentar la colaboración científica.

### **1.2. Motivación**

A pesar de la creciente disponibilidad de bases de datos públicas EEG, uno de los principales desafíos que persisten es la variabilidad de la calidad de los datos. Las señales cerebrales registradas son altamente sensibles a diversas fuentes de contaminación, como ruido eléctrico, movimientos musculares, parpadeos o incluso la respiración del sujeto [3]. Aunque existen algoritmos y herramientas diseñados para el preprocesamiento y la limpieza de estos registros, la calidad inicial de los datos sigue siendo determinante para su utilidad en posibles estudios futuros [4].

En muchos casos, sobre todo cuando se cuenta con datasets extensos, realizar una revisión manual de los datos se vuelve una tarea difícil. Una parte de este trabajo se podría automatizar, a través del uso de criterios objetivos específicos en base a los cuales se pueda estimar y comparar la calidad de distintas bases de datos.

### **1.3. Objetivos**

El objetivo general de este trabajo es realizar una evaluación comparativa de las bases de datos EEG más recientes relacionadas con la escucha de música, con el fin de determinar cuáles presentan mejores condiciones para futuras investigaciones. Para ello, se plantean los siguientes objetivos específicos:

- Recopilar un conjunto representativo de bases de datos EEG públicas enfocadas en tareas de escucha musical.
- Definir y aplicar un conjunto de criterios automáticos que evalúen aspectos clave como la presencia de ruido, valores atípicos, canales defectuosos y sujetos o épocas inutilizables.
- Elaborar una clasificación basada en la calidad relativa de cada base de datos, que pueda servir como guía para futuros estudios sobre las mismas.

## 2. Estado del Arte

### 2.1. Sobre EEG

#### ¿Qué es un EEG?

Un EEG es un método que permite registrar la actividad eléctrica cerebral producida por la activación simultánea y sincronizada de un grupo de neuronas situadas próximas al cráneo. Colocando pequeños elementos conductores (electrodos) sobre distintas ubicaciones del cuero cabelludo, es posible registrar el voltaje producido en una sección del cerebro gracias al fenómeno de conducción de volumen [5]. Si se toman muestras de estos valores a lo largo del tiempo, se termina obteniendo una señal discreta, que muestra la evolución de las diferencias de potencial entre las distintas localizaciones de los electrodos. En la Figura 1 se muestra un ejemplo de este tipo de registros, que suele presentar formas de ondas sinusoidales.

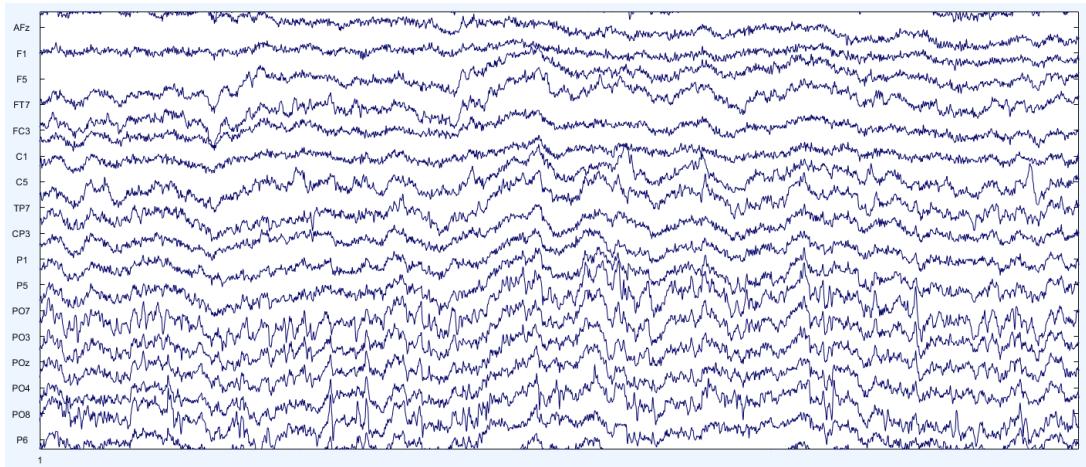


Figura 1: Ejemplo de registro EEG (1 segundo).

#### Ritmos

Las señales registradas en un EEG se caracterizan principalmente por sus componentes en diferentes bandas de frecuencia, comúnmente conocidas como ritmos cerebrales. Estos ritmos están estrechamente relacionados con diversas actividades y procesos cerebrales [6]. Por ejemplo:

- **Delta** (0.5–4 Hz): Sueño profundo.
- **Theta** (4–7 Hz): Somnolencia o meditación.
- **Alpha** (8–12 Hz): Relajación con ojos cerrados, estado de reposo mental.
- **Beta** (13–30 Hz): Actividad mental normal, concentración, alerta.
- **Gamma** (30–70 Hz o más): Procesamiento sensorial y funciones cognitivas complejas.

En la Figura 2 se ve un ejemplo de las diferencias entre los diferentes tipos de ritmos.

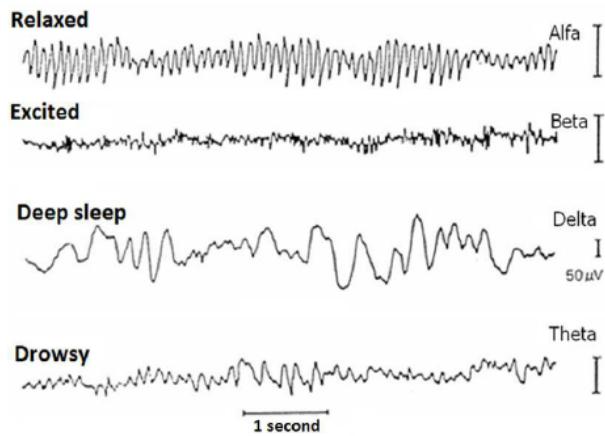


Figura 2: Diferentes tipos de ritmos presentes en las señales EEG [7].

### Montajes de EEG

La manera en la que se conectan los electrodos para representar la actividad eléctrica cerebral se conoce como “montaje”. Cada electrodo capta señales locales, pero a través de los montajes se permite interpretar el contexto espacial mediante la comparación con diferentes zonas del cuero cabelludo. Existen dos tipos de montajes principalmente:

- **Bipolares:** comparan cada electrodo con uno adyacente. El más común es el Doble Banana y es útil cuando se miden ritmos de amplitud media a baja que están muy localizados.
- **Referenciales:** comparan todos los electrodos con un punto de referencia común. Esta referencia común suelen ser los lóbulos de las orejas o el promedio de todos los electrodos.

La manera más habitual de colocar los electrodos en el cuero cabelludo es el sistema 10-20, que divide las distancias de la cabeza en porcentajes de 10 % y 20 %. Cada electrodo se nombra con una letra (zona cerebral: F = Frontal, T = Temporal, etc.) y un número (impar = hemisferio izquierdo, par = hemisferio derecho). Los electrodos centrales llevan la letra Z. También se pueden utilizar otros electrodos adicionales como M1 y M2 situados en los lóbulos de las orejas, que se utilizan como referencias comunes [8]. En la Figura 3 se puede ver la distribución espacial del sistema 10-20.

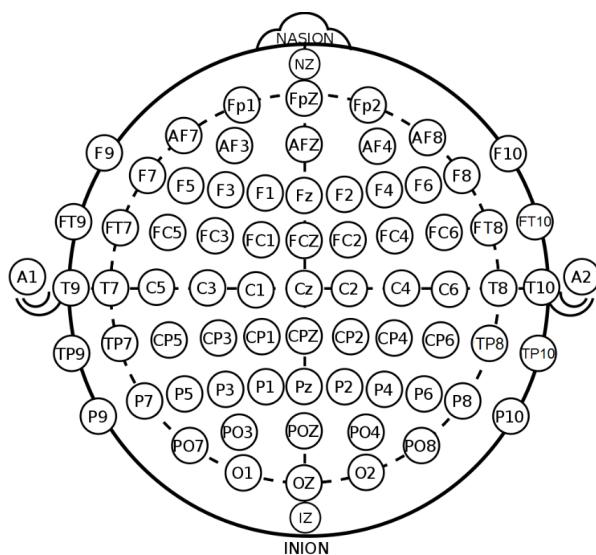


Figura 3: Distribución espacial del sistema 10-20. [DOI:10.13140/RG.2.1.2608.7842]

## **Artefactos y ruido**

Durante las sesiones de registro de datos EEG, es habitual que los electrodos terminen registrando señales que no están relacionadas con actividades cerebrales. Este tipo de señales, que suelen interferir con los datos de interés, se conocen como artefactos. Existen múltiples tipos de causas para los artefactos. Las más comunes son:

- **Movimientos Oculares:** Los movimientos oculares típicamente producen suficiente actividad eléctrica como para poder influir en los datos de un EEG, sobre todo en los electrodos más cercanos al lóbulo frontal.
- **Movimientos Musculares:** Estos artefactos se suelen producir más cuando el sujeto está despierto y corresponden sobre todo a interferencias producidas al tragar, bostezar, movimientos involuntarios, etc. Todo este tipo de acciones pueden tener un influencia en los datos EEG finales.
- **Actividad Cardíaca:** Debido a la distancia, la actividad eléctrica del corazón no suele afectar demasiado a la actividad eléctrica del cuero cabelludo. Sin embargo, esto puede depender de la distribución de electrodos. Si uno de ellos está colocado en proximidad a algún vaso sanguíneo importante de la cabeza, es posible que se registre también una interferencia periódica constante (que corresponde a los latidos) y que pueda ser confundida con una señal EEG.
- **Ruido de línea:** Esto corresponde al propio ruido eléctrico producido por las fuentes de alimentación, que suelen trabajar con frecuencias de 50/60 Hz (en función del país). Este tipo de actividad externa al sujeto puede suponer una clara interferencia con los datos EEG.

También pueden existir artefactos relacionados con el potencial eléctrico de la propia piel, que producen interferencias con la señal EEG, o relacionados con el desprendimiento progresivo de algún electrodo, que produciría típicamente una disminución en la amplitud de la señal (i.e., canales planos).

## **Aplicaciones**

El estudio de las señales de los EEG tiene aplicaciones fundamentales en el campo de la medicina moderna. Los EEG son muy utilizados para detectar y hacer un seguimiento de trastornos neurológicos como la epilepsia u otros trastornos convulsivos, trastornos del sueño, Alzheimer, déficit de atención (ADHD), etc.

Debido a su carácter no invasivo, también han sido muy utilizados en el ámbito de la investigación y la neurociencia, ya que el estudio de las señales producidas puede ofrecer información muy valiosa relacionada con los procesos cognitivos y el procesamiento emocional. Los resultados que se obtienen a través de estos métodos permiten indagar y conocer más sobre el funcionamiento del cerebro.

Algunas de las aplicaciones EEG más relacionadas con el campo de la ingeniería y avances tecnológicos son las interfaces cerebro-computador (BCI). Este tipo de herramientas utilizan datos en tiempo real obtenidos de los EEG para controlar de manera directa otros dispositivos electrónicos y/o mecánicos [9].

### **2.2. Música como estímulo**

#### **Procesamiento neurológico de la música**

Una pieza musical se caracteriza por elementos específicos como el ritmo, la melodía, el tono, el timbre o la armonía. La combinación de estos elementos produce un estímulo acústico complejo, que en las personas involucra múltiples procesos neurológicos simultáneos, abarcando desde la parte puramente acústica hasta la más subjetiva y sentimental. A lo largo de los últimos años, ha habido un interés creciente en la comunidad neurocientífica por cómo la escucha de música influye en procesos neurales. Hay numerosos estudios que indican que la música tiene una influencia más predominante en el hemisferio derecho, especialmente en la zona del lóbulo temporal (cerca de los oídos) [10, 11, 12].

También hay estudios recientes que muestran cierto solapamiento entre las regiones cerebrales activadas tanto por la música como por el habla. En concreto, el planum polare, una región del lóbulo temporal, se ha observado que se activa de manera más notable, sobre todo ante estímulos musicales [13]. Esta región es importante no solo en la percepción de sonidos complejos como la música, sino también en el procesamiento del lenguaje, lo que sugiere que los mecanismos que procesan la música podrían estar estrechamente relacionados con los que procesan el lenguaje hablado [14].

### **Ventajas de la música como estímulo en EEG**

La música es un estímulo auditivo único que ofrece ventajas significativas frente a otros tipos de estímulos en estudios de EEG. La naturaleza estructurada y temporal de la música facilita el análisis de las respuestas cerebrales, ya que se pueden identificar patrones rítmicos y melódicos que sincronizan la actividad cerebral de manera precisa. Esto permite estudiar fenómenos como la sincronización neuronal, que es crucial para entender cómo el cerebro responde a eventos temporales en la música. Además, la música puede inducir estados emocionales muy diversos, lo que es útil para investigar cómo diferentes emociones se reflejan en las señales EEG. Por ejemplo, hay estudios que indican que la música triste puede inducir una mayor actividad en el hemisferio derecho del cerebro, mientras que la música alegre tiende a activar más el hemisferio izquierdo [15, 16]. Esta versatilidad en la inducción emocional convierte a la música en un estímulo altamente valioso en la investigación de la relación entre las emociones y la actividad cerebral.

A diferencia de otros estímulos como los videos, que incluyen componentes visuales, la música permite un enfoque más controlado en el procesamiento auditivo, lo que facilita el análisis específico de la actividad cerebral relacionada con el sonido, sin la interferencia de otros sentidos. Además, debido a su capacidad para modular las emociones de manera controlada, la música también ofrece una herramienta poderosa para estudiar la variabilidad emocional y cómo esta se manifiesta en el cerebro.

### **Tipos de estímulos musicales utilizados**

El diseño experimental en estudios de EEG con música suele involucrar distintos tipos de estímulos musicales que se seleccionan de acuerdo al objetivo del estudio. Los estímulos musicales pueden variar en cuanto a familiaridad, complejidad y género, y cada una de estas características puede influir de manera diferente en la actividad cerebral. En muchos estudios, se utilizan piezas musicales conocidas frente a música desconocida para observar cómo la familiaridad afecta la activación cerebral. La familiaridad con una pieza puede generar una respuesta emocional más fuerte y facilitar la memoria auditiva, lo que a su vez puede influir en las ondas cerebrales registradas [17, 18].

Los estudios que analizan música instrumental en comparación con música vocal también muestran diferencias en las respuestas cerebrales. Se ha encontrado que la música instrumental tiende a activar áreas cerebrales relacionadas con la percepción del ritmo y la armonía, mientras que la música con voz puede involucrar más áreas asociadas con el lenguaje y las emociones [19]. También, el género musical suele ser un factor importante, ya que géneros como la música clásica o el jazz pueden inducir respuestas cerebrales muy distintas a géneros como el pop o el rock [20]. Estos estudios ayudan a comprender cómo diferentes características musicales influyen en el cerebro y cómo se pueden emplear distintos tipos de música para inducir diferentes estados emocionales en un experimento.

### **2.3. Calidad en EEG**

#### **Factores que afectan la calidad de la señal EEG**

La calidad de las señales EEG es un factor crítico que puede influir directamente en los resultados obtenidos durante un estudio que emplee esta técnica. Una señal EEG de buena calidad permite una

interpretación más precisa de la actividad cerebral y mejora la eficacia de los análisis posteriores. Uno de los aspectos más importantes para garantizar una buena calidad en el registro EEG es la impedancia de los electrodos. Una impedancia elevada suele deberse a un mal contacto entre el electrodo y el cuero cabelludo, lo que introduce ruido e interfiere en la calidad de la señal eléctrica. Para mantener una señal limpia, suelen considerarse aceptables valores de impedancia de hasta  $10\text{ k}\Omega$ , aunque los valores deseables son inferiores a  $5\text{ k}\Omega$  [21].

Además, como se menciona en la sección 2.1, en el apartado de artefactos, la presencia de ruido fisiológico o ambiental (movimientos oculares, musculares, interferencias eléctricas, etc.) puede distorsionar significativamente la señal. Para contrarrestar este tipo de artefactos, existen herramientas y algoritmos como filtros avanzados, Análisis de Componentes Independientes (ICA) y técnicas de aprendizaje automático. Estas herramientas suelen ofrecer buenos resultados y facilitan el estudio de las señales EEG [22].

### Calidad en función del diseño experimental

La calidad también puede verse afectada por el diseño experimental. La duración del experimento es un factor importante que debe optimizarse para evitar la fatiga del sujeto, ya que esta puede inducir cambios no deseados en las señales EEG, especialmente en bandas como alfa o theta [23, 24]. Otro aspecto relevante es la naturaleza de la tarea cognitiva o motora que el sujeto realiza durante el experimento, ya que diferentes tareas pueden activar regiones cerebrales específicas y, por lo tanto, modificar la distribución espacial ypectral de las señales EEG [25].

Asimismo, es importante que el diseño considere períodos de descanso y la posible habituación del participante, la cual puede afectar notablemente la actividad cortical ante estímulos repetitivos [26]. La aleatorización de los ensayos, el control de variables externas (como el ruido auditivo), junto con el número de repeticiones de un mismo experimento, influyen directamente en la estabilidad de las señales recogidas y, por lo tanto, en su calidad.

Otro aspecto relevante para la calidad de este tipo de señales es la sincronización entre los propios estímulos y los datos recogidos por el EEG. El objetivo es maximizar la precisión temporal de estos eventos mediante marcas temporales, tratando de minimizar todo lo posible la latencia entre estímulo y marca de señal percibida.

### Selección de canales y métricas de evaluación

Para evaluar la calidad de la señal EEG, es habitual analizar métricas como la relación señal-ruido (SNR), la varianza o la potencia espectral de las distintas bandas de frecuencia [27, 28]. Otras métricas útiles incluyen el uso de kurtosis [29] y entropía [30], que permiten identificar desviaciones respecto a la morfología esperada de la señal. Además, la detección de artefactos puede realizarse mediante algoritmos automáticos como ICA o mediante modelos basados en aprendizaje automático, tales como máquinas de vectores de soporte (SVM) o redes neuronales profundas (DNN).

## 2.4. Herramientas de análisis

Dada la notable expansión del EEG en el ámbito de la investigación, se han desarrollado múltiples tecnologías especializadas para su análisis. A continuación, se describen algunas de las más relevantes:

- **PyEEG:** Se trata de un módulo desarrollado en Python orientado a la extracción y análisis de datos EEG y MEG [31]. Aunque su principal enfoque es el EEG, también cuenta con funcionalidades para el análisis de MEG. Según se detalla en el artículo original, PyEEG dispone de una amplia variedad de herramientas útiles para el análisis de EEG, incluyendo un método específico para la descomposición de la Intensidad Espectral de Potencia. Esta biblioteca está diseñada para ser utilizada como cualquier otro módulo en Python, permitiendo al usuario importar el paquete y acceder a

todas sus funciones de forma sencilla. Además, emplea NumPy, una librería ampliamente conocida en Python, como estructura principal de datos, lo que simplifica su manejo y procesamiento.

- **MNE-Python:** Este es otro paquete de código abierto escrito en Python, concebido para el análisis y preprocesamiento de señales EEG y MEG [32]. Utiliza NumPy para el almacenamiento eficiente y manipulación de datos numéricos, y SciPy para el procesamiento de señales y operaciones de álgebra lineal. MNE-Python ofrece un amplio conjunto de algoritmos avanzados, incluyendo filtrado, supresión de ruido y análisis en el dominio tiempo-frecuencia. Se trata de una de las herramientas más utilizadas en el estado del arte para el análisis de señales biomédicas.
- **BioSig:** BioSig es una herramienta ampliamente reconocida para el procesamiento general de señales biomédicas [33]. Aunque soporta lenguajes como C/C++ y Python, su módulo principal está diseñado para su uso en entornos MATLAB y Octave. Esta herramienta es capaz de procesar señales provenientes de diversas fuentes biomédicas, entre ellas el EEG, y dispone de métodos específicos para la extracción del espectro de potencia de dichas señales, facilitando así su análisis detallado.
- **EEGLAB:** EEGLAB es una toolbox ampliamente utilizada en el análisis de EEG, que ofrece funcionalidades muy potentes como la descomposición mediante Análisis de Componentes Independientes (ICA) y la extracción de la Potencia Espectral Relacionada a Eventos (ERSP) [34]. Diseñada para MATLAB, cuenta con una interfaz gráfica interactiva que facilita la navegación y el uso por parte del usuario. A pesar de esta interfaz gráfica, es posible y en muchos casos conveniente crear scripts tradicionales en MATLAB que hagan uso de las funcionalidades de EEGLAB. Además, esta toolbox soporta múltiples complementos y permite la integración de herramientas externas, incluyendo el módulo BioSig mencionado anteriormente.

Los scripts creados para este trabajo han sido desarrollados en MATLAB, utilizando EEGLAB como herramienta principal para la conversión y uso de los datos EEG.

### **3. Bases de Datos Analizadas**

En esta sección se hará una breve descripción de las bases de datos que se han seleccionado para realizar los análisis de calidad. Todos estos conjuntos de datos EEG están relacionados con la escucha de música y son de los más recientes en el estado del arte actual. Siempre que estuviese disponible, para evaluar la calidad de los datos, se usó la versión en bruto (i.e., sin preprocesar) de los datos.

#### **3.1. dsMUSING**

Conjunto de datos presentado en [35] y disponible en: <https://openneuro.org/datasets/ds003774/versions/1.0.2> que contiene las respuestas continuas de EEG de 20 sujetos mientras escuchaban 12 canciones de distintos géneros musicales. La mayoría de las canciones presentadas en este estudio no contienen letras, y su género varía desde música folclórica india hasta rock gótico y música electrónica occidental. Además, se incluyen las valoraciones de familiaridad y disfrute de todos los sujetos para cada canción.

Para llevar a cabo este experimento, los sujetos se sentaron en una habitación oscura y, en primer lugar, fueron expuestos a dos minutos de silencio con el fin de obtener una respuesta de referencia (línea base). Luego se les pidió que cerraran los ojos, escucharan la canción, abrieran los ojos y finalmente, calificaran la canción en términos de familiaridad y disfrute. Este proceso se repitió para todas las canciones.

Los datos de EEG fueron recolectados usando 128 canales, con una tasa de muestreo de 250 Hz para la mayoría de los sujetos, mientras que el resto tuvo una tasa de muestreo de 1000 Hz. Los datos en bruto fueron almacenados en archivos .set dentro de la carpeta correspondiente a cada sujeto, junto con la ubicación de los canales y los eventos etiquetados con su duración. Este formato es directamente compatible con el software de EEGLAB y está listo para ser cargado.

El conjunto de datos incluye tanto los datos en bruto no segmentados como los datos parcialmente preprocesados. Los datos parcialmente preprocesados contienen solo las respuestas de EEG correspondientes a las secciones musicales, y están divididos en subcarpetas por participante. Los datos en bruto no segmentados contienen las respuestas de EEG registradas durante toda la duración del estudio, incluyendo la línea base y otros eventos como la cuenta regresiva para el inicio del experimento o los sonidos de aviso para cerrar/abrir los ojos. Toda esta información se encuentra contenida en una sola carpeta.

#### **3.2. dsDRYAD**

Conjunto de datos presentado en [36] y disponible en: <https://datadryad.org/dataset/doi:10.5061/dryad.g1jwstqmh>. Este conjunto recoge señales corticales (EEG) de 20 sujetos mientras escuchaban melodías de Bach interpretadas en piano. El objetivo del estudio fue analizar cómo se codifican a nivel cortical las expectativas melódicas en la escucha musical natural, distinguiendo entre componentes acústicos y melódicos.

Los estímulos musicales se derivaron de obras de Bach presentadas como archivos MIDI. Los participantes fueron divididos en dos grupos: los sujetos 1 a 10 eran no músicos y los sujetos 11 a 20 eran pianistas expertos. Cada sujeto escuchó 30 fragmentos musicales distribuidos en ensayos, contando con tres repeticiones por pieza musical (i.e., 10 canciones distintas, 3 repeticiones cada una).

Los datos se recopilaron utilizando 64 electrodos en el cuero cabelludo y 2 electrodos mastoideos adicionales (canales 65 y 66), con una frecuencia de muestreo de 512 Hz. Los datos estaban almacenados en ficheros MATLAB, organizados según el formato CND (Continuous-events Neural Data). Existe un archivo común (dataStim.mat) que contiene los estímulos compartidos por todos los participantes y archivos individuales por cada sujeto (dataSubX.mat) que contienen la actividad EEG específica del participante, organizada por ensayos.

Aunque se menciona que se recolectaron valoraciones de familiaridad, estas aún no están disponibles en la versión actual del conjunto de datos.

### **3.3. dsNMEDE**

Conjunto de datos presentado en [37] y disponible en: <https://purl.stanford.edu/pp371jh5722> que contiene las respuestas corticales (EEG) y valoraciones conductuales de 24 participantes adultos mientras escuchaban música natural. Se utilizó una configuración de 128 canales de EEG para registrar la actividad cerebral durante la escucha de una interpretación de música clásica grabada en 1965. Además, los participantes escucharon una versión manipulada del mismo estímulo, generada mediante una desorganización temporal por mezclas de fase y posteriormente ajustada para conservar la dinámica del sonido original.

Cada participante escuchó ambos estímulos (intacto y manipulado) una vez, y luego calificó cada uno en términos de agrado, activación, interés, predictibilidad y familiaridad. Antes de cada estímulo, se registró una línea base de 60 segundos mientras los participantes escuchaban ruido rosa a bajo volumen.

Los datos están organizados por identificadores anónimos de participantes e incluyen tanto registros continuos de EEG en bruto (24 archivos, uno por participante) como las versiones de EEG limpiados y agrupados (4 archivos en total). Por otro lado, también incluyen en un fichero las valoraciones. Todos los archivos están en formato MATLAB.

### **3.4. dsAUTh**

Este conjunto de datos, presentado en [38] y disponible en: <https://github.com/AdamosDA/Music-EEG?tab=readme-ov-file>, cuenta con un total de 20 sujetos (6 de ellos sin formación musical) que participaron en un experimento personalizado de escucha musical pasiva, de un total de 30 canciones distintas.

Se seleccionan canciones personalizadas para cada sujeto, según su gusto musical, distribuidas en tres niveles de preferencia: baja (1), media (3) y alta (5). Una vez seleccionados los temas para cada sujeto, se procedió con la escucha pasiva de música con registro EEG, en la que se presentaron extractos de 80 segundos de cada canción seleccionada, separados por 10 segundos de silencio. Antes de la presentación de los estímulos, se grabaron 70 segundos de actividad EEG en reposo.

Se utilizó un total de 14 canales EEG, distribuidos según el sistema internacional 10-20, a una frecuencia de muestreo de 128 Hz. La sesión se desarrolló en un entorno relajado y sin tareas activas, con una breve pausa intermedia para mayor comodidad de los participantes.

En este caso, solo se cuenta con una versión de los datos preprocesada, con filtros de pasa banda (1 Hz - 45 Hz) y limpieza de artefactos con una versión modificada de ICA, todo ello aplicado a nivel de ensayo individual. Los ficheros de todos los datos son de tipo MATLAB.

### **3.5. dsRIUMA**

Conjunto de datos presentado en [39] y disponible en: <https://riuma.uma.es/xmlui/handle/10630/36947>. Contiene señales EEG registradas de 6 sujetos mientras escuchaban fragmentos de canciones pertenecientes a cuatro géneros musicales distintos: balada, clásica, metal y reguetón. Tras cada fragmento, los participantes dieron su valoración en términos de familiaridad y disfrute.

Las señales se registraron con 64 canales y con una tasa de frecuencia de 2500 Hz. En el experimento se incluyen un total de 16 canciones (4 por género), incluyendo tanto piezas populares como extractos musicales clásicos. Los datos en bruto de EEG son guardados en ficheros .eeg separados por cada sujeto y en ficheros .txt se almacena información de los estímulos presentados, incluyendo las respuestas valorativas del sujeto.

## **4. Metodología**

En esta sección detallaremos la metodología implementada para evaluar la calidad de las bases de datos seleccionadas.

### **4.1. Conversión de los datos**

Como se mencionó anteriormente en la Sección 3, los datos se presentan en distintos formatos de archivos, rutas y estructuras. Antes de iniciar el análisis de calidad, es necesario realizar una etapa de estandarización. En primer lugar, se unificará el formato de las rutas de acceso a los datos, lo cual facilitará su gestión en etapas posteriores. Además, se convertirá todo el contenido al formato .set, normalizando también las secciones incluidas en cada archivo, sincronizando adecuadamente los estímulos con los eventos correspondientes, entre otros ajustes necesarios. Es importante destacar que en estas conversiones no se ha realizado ningún procedimiento de preprocesado, por lo que los datos siguen mostrando la información original (en bruto) proporcionada por cada conjunto de datos.

#### **Conversión dsMUSING**

La base de datos MUSING contiene señales EEG registradas mientras los participantes escuchaban fragmentos musicales, clasificando después cada canción en función de sus preferencias subjetivas. Los datos originales están organizados en formato .set, uno por sujeto, y contienen tanto las señales continuas como los eventos etiquetados correspondientes a cada canción.

Con el objetivo de estandarizar el análisis, se ha llevado a cabo un procedimiento de conversión y segmentación por canción. Cada archivo original incluye eventos del tipo 'stm+' (inicio de canción) y 'fxnd' (fin de canción), lo que permite identificar con precisión el intervalo temporal correspondiente a cada estímulo musical.

El script de conversión recorre todos los sujetos, extrayendo los segmentos EEG entre los eventos 'stm+' y 'fxnd' para cada una de las 12 canciones reproducidas. A continuación, guarda cada segmento como un archivo independiente en formato .set, organizándolos en subcarpetas por sujeto y por canción, facilitando su análisis individualizado y sincronizando de manera clara los datos con los estímulos musicales presentados.

El resultado de esta conversión es una estructura de datos estandarizada, con un archivo .set por canción y por sujeto, lo que permite una integración más directa con los próximos flujos de trabajo.

#### **Conversión dsNMEDE**

La base de datos NMEDE contiene registros EEG de alta resolución (129 canales, 1000 Hz de muestreo) adquiridos mientras los sujetos escuchaban dos versiones distintas de una misma pieza musical. El diseño experimental incluye además fases de descanso y valoraciones subjetivas, codificadas mediante eventos digitales.

Para su estandarización, se desarrolló un script que procesa los datos .mat originales por sujeto. Cada archivo contiene las señales EEG, la frecuencia de muestreo y una secuencia de disparos (DIN\_1) que codifica el flujo experimental. El script utiliza funciones de parsing personalizadas para identificar los momentos exactos en los que comienza la fase de descanso, la escucha musical y la fase de evaluación.

Posteriormente, los datos se segmentan por cada una de las dos canciones, extrayendo el periodo comprendido entre el inicio del baseline y el comienzo de la evaluación subjetiva. A estos segmentos se les asocian eventos estructurados en los objetos EEG.event y EEG.epoch, asegurando la correcta sincronización entre los estímulos y los datos EEG.

Finalmente, los datos segmentados se almacenan nuevamente en archivos .set, organizados por sujeto y por canción.

### **Conversión dsDRYAD**

La base de datos DRYAD se compone de señales EEG registradas mientras los sujetos escuchaban 10 piezas musicales diferentes, cada una repetida en tres ocasiones, dando lugar a un total de 30 ensayos por participante. Las señales se encuentran en formato .mat, estructuradas como una celda por ensayo, acompañadas de metadatos como la frecuencia de muestreo, información de canales y un periodo de padding inicial.

Durante la conversión, cada canción es procesada individualmente por sujeto. Para cada pieza, se agrupan sus tres repeticiones en una estructura EEG tridimensional (canales × muestras × ensayos), facilitando su tratamiento como un conjunto de épocas dentro de un único archivo .set.

Cada repetición se marca con un evento específico situado tras el padding inicial (latencia 513), permitiendo identificar con precisión el inicio de cada ensayo. Estos eventos se codifican con etiquetas descriptivas que combinan el número de canción y de repetición (e.g., "Song 3/Trial 2").

Finalmente, se construyen los campos EEG.event y EEG.epoch, asegurando la correcta indexación y consistencia del conjunto de datos. Los archivos resultantes, uno por canción y por sujeto, quedan almacenados en formato .set y organizados en carpetas, quedando listos para el análisis en entornos como EEGLAB.

### **Conversión dsRIUMA**

El conjunto de datos RIUMA se presenta en formato BrainVision (.eeg + .vhdr) y contiene registros EEG correspondientes a 16 canciones diferentes escuchadas por varios sujetos. Cada archivo contiene eventos que indican el inicio de cada estímulo musical, marcados como "S XX" (donde XX representa el número de canción). En este caso, como los identificadores de los sujetos no siguen una secuencia lineal, se ha creado un índice externo para ir recorriendo a los sujetos.

Durante la conversión, para cada sujeto se cargan los datos completos y se extraen segmentos de 30 segundos correspondientes a cada una de las 16 canciones, a partir de los eventos etiquetados individualmente. Estos segmentos se guardan como archivos independientes en formato .set.

Dado que los archivos originales no incluyen información sobre las ubicaciones de los electrodos (chanlocs), se utiliza una plantilla estándar proporcionada por EEGLAB para asociar las posiciones de los canales a la estructura EEG, en base a sus etiquetas. Esto permite mantener la compatibilidad con posteriores análisis, aunque con una precisión limitada respecto a la configuración real del sistema de adquisición.

Cada archivo .set resultante incluye únicamente los datos de una canción y se organiza en carpetas por sujeto y canción.

### **Conversión dsAUTh**

El conjunto de datos AUTh contiene registros EEG de 20 sujetos expuestos a 30 fragmentos musicales diferentes. Para cada canción, se registran señales EEG multicanal junto con valoraciones subjetivas sobre la experiencia musical del participante. Cada archivo de sujeto (.mat) contiene: Datos EEG segmentados por canción (EEG\_Songs); Información de los sensores (sensor\_info) incluyendo etiquetas y coordenadas en 2D; Frecuencia de muestreo (Fs); Valoraciones individuales de las canciones (song\_ratings).

Las ubicaciones de los electrodos se extraen directamente del archivo original del sujeto y se incluyen en cada estructura EEG como chanlocs, asumiendo una coordenada Z=0 (proyección en el plano 2D).

Durante la conversión, se crea un archivo .set independiente para cada canción escuchada por un sujeto. Estos archivos se organizan jerárquicamente en carpetas por sujeto y canción.

Cada .set también incluye un marcador de evento al inicio del archivo, con el nombre song:XX/rating:YY, que identifica el número de canción y la valoración subjetiva dada por el participante, lo que facilita su uso posterior en análisis de correlación entre EEG y respuesta emocional o estética.

Nuevamente, en este caso es importante destacar que los datos iniciales venían ya con ciertos elementos de preprocessado aplicados que pueden tener una influencia notoria en los futuros análisis. Por ejemplo, al tener aplicado un filtro pasa banda (1 Hz - 45 Hz), no es posible extraer información de frecuencias superiores a 45 Hz.

#### **4.2. Análisis de Calidad**

Una vez estandarizado el formato de los datos, se procederá a evaluar su calidad. Para ello, se definirán e implementarán una serie de criterios objetivos que permitirán identificar y filtrar tanto la proporción de canales utilizables por sujeto como las secciones temporales con buena calidad de señal. A partir de estos resultados, se podrá elaborar una clasificación global de todos los conjuntos de datos, lo que permitirá determinar, según dichos criterios, cuáles son los más adecuados o cuáles podrían ofrecer mejores resultados en análisis posteriores.

##### **Criterio 1: Canales planos**

Como se mencionó en la Sección 2, se consideran canales planos aquellos cuya señal es muy débil o prácticamente nula en comparación con los demás canales del registro EEG. Este criterio tiene como objetivo detectar la existencia y proporción de estos canales, que generalmente corresponden a electrodos desconectados, con mal contacto o cubiertos de artefactos.

Para ello, existen herramientas ya desarrolladas, como la función `clean_flatlines` del plug-in `clean_rawdata2.0` de EEGLAB. Esta función identifica, en cada canal, regiones en las que la variación entre muestras consecutivas es extremadamente baja. Si dicha baja variación se mantiene durante un período mayor a un umbral predefinido, el canal es marcado como defectuoso.

Como no es habitual que un canal esté registrando señales planas durante un tiempo y posteriormente comience a registrar bien, una posible alternativa a este método sería simplemente calcular la desviación estándar para la serie temporal de los canales y compararlo en base a un valor fijo.

Finalmente se optó por implementar para este primer criterio la variante de `clean_flatlines`, ya que es una herramienta más probada y fácilmente ajustable. En pruebas posteriores se observó que los conjuntos de datos tienen muy pocos canales planos en general, por lo que este criterio no suele marcar canales como malos.

##### **Criterio 2: Baja correlación con el resto de canales**

La baja correlación entre un canal y el resto puede indicar que la señal registrada está contaminada por artefactos, como ruido eléctrico o fallos en la conexión del electrodo.

Una primera variante considerada fue evaluar la correlación entre cada canal y la mediana de sus canales vecinos. Para ello, se requiere contar con las coordenadas espaciales de los electrodos. A partir de estas coordenadas, se calcula una matriz de proximidad basada en una distancia umbral (por ejemplo, menor a una cuarta parte de la distancia máxima entre electrodos). Con esta matriz, se definen los vecinos de cada canal. Posteriormente, se aplica una ventana deslizante sobre el tiempo y se calcula la correlación entre el canal y la mediana de sus vecinos. Si la correlación promedio en todas las ventanas es inferior a un umbral (e.g., 0.75), el canal se marca como defectuoso.

Otra variante, más estándar, es la que ofrece `clean_channels`, también parte del plug-in `clean_rawdata2.0`. Esta función emplea el algoritmo RANSAC para estimar una señal esperada mediante interpolaciones espaciales basadas en canales aleatorios y luego compara la señal real de cada canal con esta estimación. Si la correlación obtenida es inferior a un umbral establecido (por defecto, 0.8) durante un tiempo prolongado, el canal es marcado como malo.

Comparando ambos métodos, se observó que la primera variante presenta ciertas limitaciones, especialmente en canales periféricos con pocos vecinos, donde la señal puede estar contaminada pero aún así presentar una correlación moderada debido al pequeño grupo de comparación. Por ello, para aplicar este segundo criterio, se ha decidido usar la variante estándar de `clean_channels`.

### Criterios 3 y 4: Valores atípicos en Bajas y Altas frecuencias

El tercer criterio se enfoca en detectar canales con potencia anormalmente alta en las bandas de baja frecuencia (1 Hz - 10 Hz). Estos valores atípicos suelen corresponder a artefactos de movimiento o respiración. Por otro lado, el cuarto criterio se centra en canales con potencia excesiva en las altas frecuencias (65 Hz - 90 Hz), lo que puede indicar la presencia de ruido eléctrico o actividad muscular.

Generalmente, este tipo de análisispectral no se utiliza para descartar directamente canales enteros, si no para identificar ventanas temporales en las que se produce actividad anómala. Si un canal acumula muchas ventanas con comportamiento atípico, es posible considerar que su señal está notablemente contaminada, y por tanto, marcarse como defectuoso; aunque estos casos no suelen ser habituales.

Para ambos criterios, realizamos un análisis en ventanas temporales de 1 segundo de duración, sin solapamiento, aplicando el método de Welch a cada segmento para estimar la densidad espectral de potencia (PSD) por canal. Convertimos esta potencia a decibelios (dB) y promediamos dentro de los dos rangos de frecuencia definidos para cada ventana y canal: 1–10 Hz para el criterio 3 (bajas frecuencias) y 65–90 Hz para el criterio 4 (altas frecuencias). Sobre estos valores, aplicamos un criterio basado en el rango intercuartílico (IQR) para cada canal, de manera que esto se aplique a todas las ventanas. Se considera como atípica cualquier potencia que se aleje más de 3 veces el IQR del rango intercuartílico. Para cada criterio, se identifican tanto las ventanas como los canales donde se producen estos valores atípicos.

Para determinar si un canal debe considerarse como defectuoso, se calcula el porcentaje de ventanas en las que presenta valores anómalos. Si este porcentaje supera un umbral definido (10 % en este caso), el canal se marca como malo. De manera análoga, también se detectan ventanas anómalas si más del 5 % de los canales son atípicos en esa ventana.

### Implementación General

Para llevar a cabo el flujo completo del análisis, se ha desarrollado una clase en MATLAB que automatiza la aplicación de todos los criterios descritos anteriormente sobre los datos EEG. Esta clase procesa sistemáticamente todos los sujetos, canciones, canales y ventanas temporales de un conjunto de datos, generando al final un resumen global de los resultados obtenidos para cada uno de los criterios evaluados.

Al aplicar esta clase sobre distintos datasets, se obtienen resúmenes comparables que permiten evaluar la calidad relativa de cada conjunto de datos en términos de la cantidad de canales y ventanas descartados, facilitando así la elección de los registros más limpios o adecuados para análisis posteriores. Es importante destacar que, para el caso particular de dsDRYAD (que tiene 3 repeticiones por ensayo), la señal EEG que se analiza es la media sobre las 3 repeticiones, para cada canción.

Antes de aplicar los criterios anteriormente descritos, se realiza un preprocesamiento mínimo de los datos de entrada. Este preprocesado incluye un submuestreo a 256 Hz, en caso de que la frecuencia de muestreo original fuese superior, un cambio de referencia a la media y un filtrado de paso alto para 0.4 Hz. El

submuestreo se realiza con la función `pop_resample`, la cual aplica por defecto un filtro pasa baja (anti-aliasing) con una frecuencia de corte al 90 % de la nueva frecuencia de Nyquist. Para el filtrado paso alta se emplea la función `pop_eegfiltnew`, que implementa un filtro de Respuesta Finita al Impulso (FIR) diseñado para atenuar las frecuencias por debajo del umbral específico (en este caso, 0.4 Hz).

Además, la clase incorpora una funcionalidad para exportar los resultados gráficos más relevantes en formato PDF, generando un informe individual por sujeto. Esta característica ha sido especialmente útil para validar visualmente el comportamiento de los criterios y realizar ajustes en caso de detectar inconsistencias.

Entre los gráficos que se pueden exportar se incluyen:

- Mapas topográficos por canción, mostrando la distribución espacial y el porcentaje de canales eliminados, desglosado por criterio (Figura 4).
- Gráficas de series temporales para los criterios 1 y 2, permitiendo observar la evolución y el momento en el que se identifican los canales como defectuosos (Figura 5).
- Diagramas tipo boxplot para el criterio 3 (baja frecuencia) (Figura 6) y criterio 4 (alta frecuencia) (Figura 7), en los que se visualizan los valores atípicos detectados por canal, facilitando la identificación de canales con potencia espectral anómala. En los PDF originales que se exportan, la resolución de cada imagen es establecida a un valor muy alto, por lo que se puede hacer zoom sin perder calidad.

Una vez finalizada la ejecución, los valores más relevantes obtenidos por los criterios son guardados en una estructura de MATLAB y exportados a un fichero .mat. De esta manera, los datos pueden ser usados para futuros análisis comparativos entre los distintos conjuntos de datos.

#### Removed Channels by each Criteria

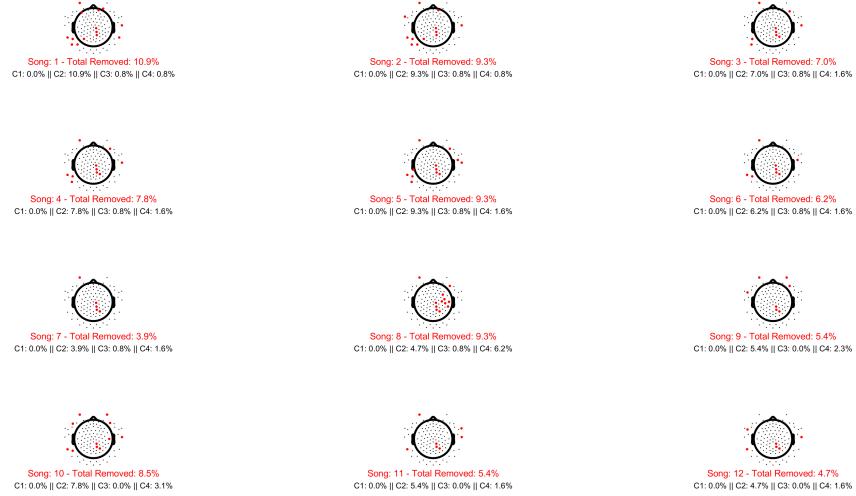


Figura 4: Ejemplo de mapas topográficos con los canales eliminados de un sujeto.

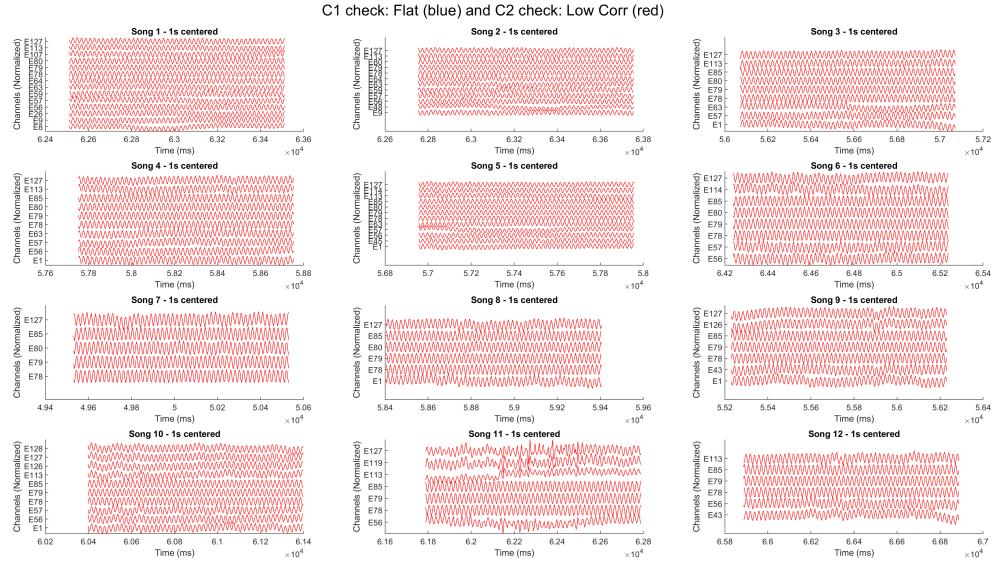


Figura 5: Ejemplo de series temporales de los canales eliminados por C1 y C2.

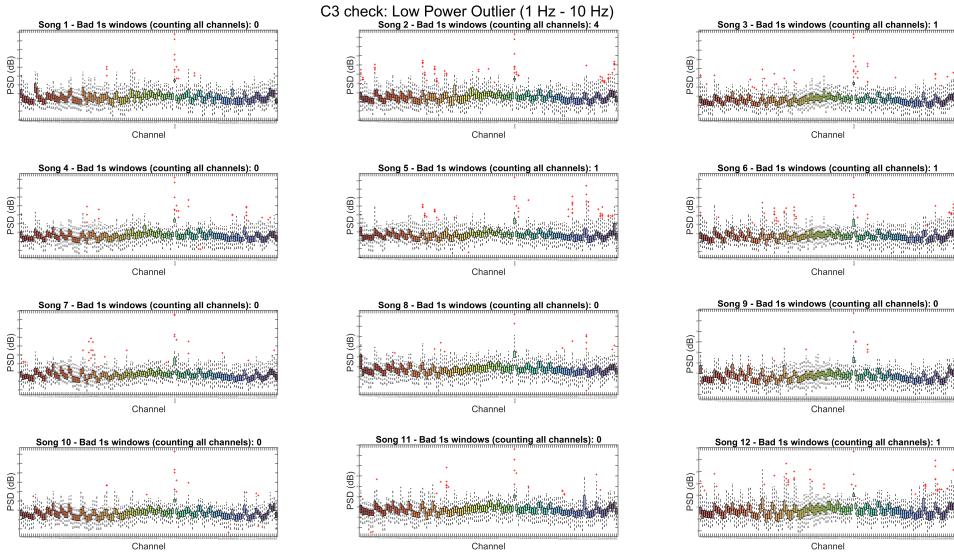


Figura 6: Ejemplo de boxplots por cada canal, evaluando ventanas para baja frecuencia.

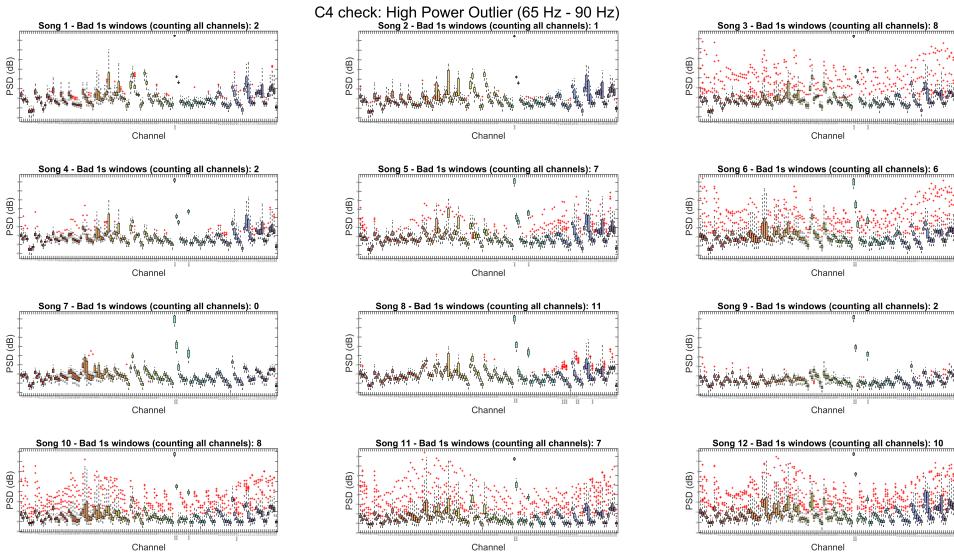


Figura 7: Ejemplo de boxplots por cada canal, evaluando ventanas para alta frecuencia.

## 5. Resultados

Una vez aplicada la metodología anterior, generamos resúmenes descriptivos que reflejan los resultados finales de la aplicación de todos los criterios establecidos previamente. En las figuras del Anexo B se pueden observar los gráficos descriptivos globales separados por cada conjunto de datos de manera independiente.

### Mapa de Calor

El mapa de calor representa visualmente el porcentaje de canales de baja calidad (izquierda) y ventanas de baja calidad (derecha) por canción y por sujeto. Para ello, se ha construido una matriz donde cada fila corresponde a un sujeto y cada columna a una canción. En el primer mapa, se calcula el porcentaje de canales de baja calidad por canción según los cuatro criterios de calidad. Se suman todos los canales únicos marcados como de baja calidad y se divide entre el total de canales para obtener un porcentaje por canción. En el segundo mapa, se suman todas las ventanas marcadas como de baja calidad por los criterios C3 y C4 (artefactos espectrales) y se divide entre el número total de ventanas de cada canción. Esto permite detectar patrones de calidad baja por canción y por sujeto, identificando fácilmente qué combinaciones presentan mayor nivel de ruido o fallos.

### Gráfico circular

El gráfico circular representa el nivel global de calidad de los datos desde dos perspectivas. A la izquierda, se muestra el porcentaje de sujetos considerados con alta calidad de datos, definidos como aquellos en los que al menos el 80 % de sus canciones tienen menos del 20 % de canales de baja calidad. A la derecha, se presenta el porcentaje de canciones de alta calidad, es decir, aquellas en las que más del 80 % de los canales se consideran de alta calidad. Este tipo de representación permite hacer una comparación rápida y muy visual entre diferentes conjuntos de datos.

### Gráfico de barras

El gráfico de barras muestra los números absolutos de canales y ventanas clasificadas como alta o baja calidad, sumando todos los registros del conjunto de datos. Para los canales, se considera de baja calidad cualquier canal que haya sido marcado como tal por al menos uno de los cuatro criterios de calidad. Para las ventanas, se contabilizan aquellas clasificadas como de baja calidad por los criterios espectrales (C3 o C4). Cabe recordar que las ventanas que se muestran representan segundos de canciones.

El objetivo de este gráfico es ofrecer una perspectiva cuantitativa del volumen de datos que ha sido descartado durante la evaluación, permitiendo valorar la eficiencia del conjunto de datos desde el punto de vista del aprovechamiento real de la señal EEG y de su proporción numérica.

### Comparativa final

Tras analizar los resultados obtenidos, se observa que, en base a los criterios definidos previamente, los conjuntos dsDRYAD y dsRIUMA presentan las mejores métricas de calidad de entre los cinco seleccionados. Ambos datasets cuentan con una alta proporción de sujetos de alta calidad, así como un elevado número de canciones y ventanas temporales (segmentos de un segundo) clasificadas como utilizables.

Particularmente, el conjunto dsRIUMA supera con una gran diferencia a dsDRYAD en cuanto a la proporción total de sujetos considerados de alta calidad. No obstante, al examinar el gráfico de barras correspondiente, se aprecia una diferencia significativa entre ambos en términos absolutos (no porcentuales) de canales y ventanas de señal utilizables, siendo claramente superior en el caso de dsDRYAD.

A esta diferencia habría que añadir el hecho de que dsDRYAD incluye también tres repeticiones por ensayo (que no se toman en cuenta), lo que puede llegar a incrementar más la diferencia entre ambos.

En contraste, dsRIUMA solo cuenta con una repetición por canción. Además, esta comparación se ve condicionada por la diferencia en el número de sujetos y en la duración de los estímulos musicales ya que dsRIUMA incluye únicamente seis sujetos y dieciséis canciones de 30 segundos cada una, mientras que dsDRYAD contiene registros de diez sujetos con fragmentos musicales que se extienden por varios minutos.

Por lo tanto, aunque ambos conjuntos han destacado por su calidad, dsDRYAD ofrece una mayor riqueza cuantitativa de datos, lo que lo convierte en una opción más robusta para estudios que requieran un volumen amplio de señales EEG limpias.

## 6. Conclusiones

En este trabajo de investigación se ha llevado a cabo una evaluación de la calidad de diversas bases de datos públicas de EEG registradas durante tareas de escucha musical. Para ello, se implementó una metodología automatizada basada en criterios objetivos, con el fin de identificar efectos de artefactos comunes que pueden llegar a producir canales defectuosos y ventanas temporales con señal de baja calidad.

Se concluye que se han cumplido satisfactoriamente los objetivos propuestos inicialmente: se ha recopilado un conjunto representativo de bases de datos recientes, se han definido e implementado criterios de evaluación cuantitativa y se ha elaborado una clasificación relativa de la calidad de cada conjunto. Esto ha permitido determinar qué bases de datos presentan mejores condiciones para su reutilización en investigaciones futuras.

Los resultados obtenidos indican que la calidad de los registros EEG puede variar notablemente entre conjuntos, incluso cuando todos ellos están enfocados en estímulos musicales similares. En particular, los conjuntos dsDRYAD y dsRIUMA destacan por presentar un alto porcentaje de datos utilizables y sujetos de alta calidad, aunque con diferencias importantes en cuanto al volumen total de información.

## Referencias

- [1] Jingyi Wang, Zhiqun Wang, and Guiran Liu. Recording brain activity while listening to music using wearable eeg devices combined with bidirectional long short-term memory networks. *Alexandria Engineering Journal*, 109:1–10, 2024.
- [2] B. B. El Sayed, M. A. Basheer, M. S. Shalaby, H. R. El Habashy, and S. H. Elkholly. The power of music: impact on eeg signals. *Psychological Research*, 89(1):42, January 2025.
- [3] William O. Tatum, Barbara A. Dworetzky, and Donald L. Schomer. Artifact and recording concepts in eeg. *Journal of Clinical Neurophysiology*, 28(3):252–263, June 2011.
- [4] Arnaud Delorme. Eeg is better left alone. *Scientific Reports*, 13(1):2372, 2023.
- [5] Seward B. Rutkove. *Introduction to Volume Conduction*, pages 43–53. Humana Press, Totowa, NJ, 2007.
- [6] C. S. Nayak and A. C. Anilkumar. *EEG Normal Waveforms*. StatPearls Publishing, Treasure Island (FL), 2025. [Updated 2023 Jul 24].
- [7] Marcin Kołodziej. Brain-computer interface as measurement and control system the reviewpaper. *Metrology and Measuring Systems*, 08 2012.
- [8] Mona Sazgar and Michael G. Young. *Overview of EEG, Electrode Placement, and Montages*, pages 117–125. Springer International Publishing, Cham, 2019.
- [9] Christoph Guger, Nuri Firat Ince, Milena Korostenskaja, and Brendan Z. Allison. *Brain-Computer Interface Research: A State-of-the-Art Summary 11*, pages 1–11. Springer Nature Switzerland, Cham, 2024.
- [10] Serge Samson and Robert J. Zatorre. Contribution of the right temporal lobe to musical timbre discrimination. *Neuropsychologia*, 32(2):231–240, February 1994.
- [11] Robert J. Zatorre and Andrew R. Halpern. Effect of unilateral temporal-lobe excision on perception and imagery of songs. *Neuropsychologia*, 31(3):221–232, March 1993.
- [12] Cécile Liégeois-Chauvel, Isabelle Peretz, Manel Babaï, Vassilis Laguitton, and Pierre Chauvel. Contribution of different cortical areas in the temporal lobes to music processing. *Brain*, 121(10):1853–1867, October 1998.
- [13] Arafat Angulo-Perkins, William Aubé, Isabelle Peretz, Fernando A. Barrios, Jorge L. Armony, and Luis Concha. Music listening engages specific cortical regions within the temporal lobes: Differences between musicians and non-musicians. *Cortex*, 59:126–137, 2014.
- [14] Aniruddh D. Patel. *Music, Language, and the Brain*. Oxford University Press, 2008.
- [15] L.A. Schmidt and Laurel Trainor. Frontal brain electrical activity (eeg) distinguishes valence and intensity of musical emotions. *Cognition and Emotion*, 15:487–500, 01 2001.
- [16] Richard J. Davidson and William Irwin. The functional neuroanatomy of emotion and affective style. *Trends in Cognitive Sciences*, 3(1):11–21, 1999.
- [17] Isabelle Peretz and Robert J. Zatorre. Brain organization for music processing. *Annual Review of Psychology*, 56:89–114, 2005.
- [18] Petr Janata. The neural architecture of music-evoked autobiographical memories. *Cerebral Cortex*, 19(11):2579–2594, 2009.
- [19] Elvira Brattico, Vinoo Alluri, Brigitte Bogert, Thomas Jacobsen, Nuutti Vartiainen, Sirke K. Nieminen, and Mari Tervaniemi. A functional mri study of happy and sad emotions in music with and without lyrics. *Frontiers in Psychology*, volume 2 - 2011, 2011.

- [20] Vinoo et al. Alluri. Large-scale brain networks emerge from dynamic processing of musical timbre, key and rhythm. *NeuroImage*, 59(4):3677–3689, 2012.
- [21] Joanna Górecka and Przemysław Makiewicz. The dependence of electrode impedance on the number of performed EEG examinations. *Sensors (Basel)*, 19(11):2608, June 2019.
- [22] Jose Antonio Urigüen and Begoña Garcia-Zapirain. Eeg artifact removal—state-of-the-art and guidelines. *Journal of Neural Engineering*, 12(3):031001, 2015.
- [23] Edmund Wascher, Björn Rasch, Jessica Sänger, Sven Hoffmann, Daniel Schneider, Gerhard Rinckenauer, Herbert Heuer, and Ingmar Gutberlet. Frontal theta activity reflects distinct aspects of mental fatigue. *Biol. Psychol.*, 96:57–65, February 2014.
- [24] Maarten A S Boksem, Theo F Meijman, and Monique M Lorist. Effects of mental fatigue on attention: an ERP study. *Brain Res. Cogn. Brain Res.*, 25(1):107–116, September 2005.
- [25] Zhen Xue, Wenxiao Zhong, Yong Cao, Shuang Liu, and Xingwei An. Impact of different auditory environments on task performance and EEG activity. *Brain Res. Bull.*, 220(111142):111142, January 2025.
- [26] Izabela Rejer, Daniel Wacewicz, Mateusz Schab, Bartosz Romanowski, Kacper Lukasiewicz, and Michał Maciaszczyk. Stressors length and the habituation effect—an EEG study. *Sensors (Basel)*, 22(18):6862, September 2022.
- [27] Maria Carla Piastra, Andreas Nüßing, Johannes Vorwerk, Maureen Clerc, Christian Engwer, and Carsten H Wolters. A comprehensive study on electroencephalography and magnetoencephalography sensitivity to cortical and subcortical sources. *Hum. Brain Mapp.*, 42(4):978–992, March 2021.
- [28] Shaun D Fickling, Careesa C Liu, Ryan C N D’Arcy, Sujoy Ghosh Hajra, and Xiaowei Song. Good data? the EEG quality index for automated assessment of signal quality. In *2019 IEEE 10th Annual Information Technology, Electronics and Mobile Communication Conference (IEMCON)*. IEEE, October 2019.
- [29] Mohammad Shahbakhti, Ana Santos Rodrigues, Piotr Augustyniak, Anna Broniec-Wójcik, Andrius Sološenko, Matin Beiramvand, and Vaidotas Marozas. SWT-kurtosis based algorithm for elimination of electrical shift and linear trend from EEG signals. *Biomed. Signal Process. Control*, 65(102373):102373, March 2021.
- [30] Alessia Cacciotti, Chiara Pappalettera, Francesca Miraglia, Paolo Maria Rossini, and Fabrizio Vecchio. EEG entropy insights in the context of physiological aging and alzheimer’s and parkinson’s diseases: a comprehensive review. *GeroScience*, 46(6):5537–5557, December 2024.
- [31] Forrest Bao, Xin Liu, and Christina Zhang. Pyeeg: an open source python module for eeg/meg feature extraction. *Computational intelligence and neuroscience*, 2011:406391, 01 2011.
- [32] Alexandre Gramfort, Martin Luessi, Eric Larson, Denis A. Engemann, Daniel Strohmeier, Christian Brodbeck, Roman Goj, Mainak Jas, Teon Brooks, Lauri Parkkonen, and Matti Hämäläinen. Meg and eeg data analysis with mne-python. *Frontiers in Neuroscience*, 7, 2013.
- [33] Carmen Vidaurre, Tilmann Sander, and Alois Schlögl. Biosig: The free and open source software library for biomedical signal processing. *Computational intelligence and neuroscience*, 2011:935364, 01 2011.
- [34] Clemens Brunner, Arnaud Delorme, and Scott Makeig. Eeglab – an open source matlab toolbox for electrophysiological research. *Biomedizinische Technik. Biomedical engineering*, 58 Suppl 1, 09 2013.
- [35] Krishna Prasad Miyapuram, Nashra Ahmad, Pankaj Pandey, and James Derek Lomas. Electroencephalography (EEG) dataset during naturalistic music listening comprising different genres with familiarity and enjoyment ratings. *Data Brief*, 45(108663):108663, December 2022.

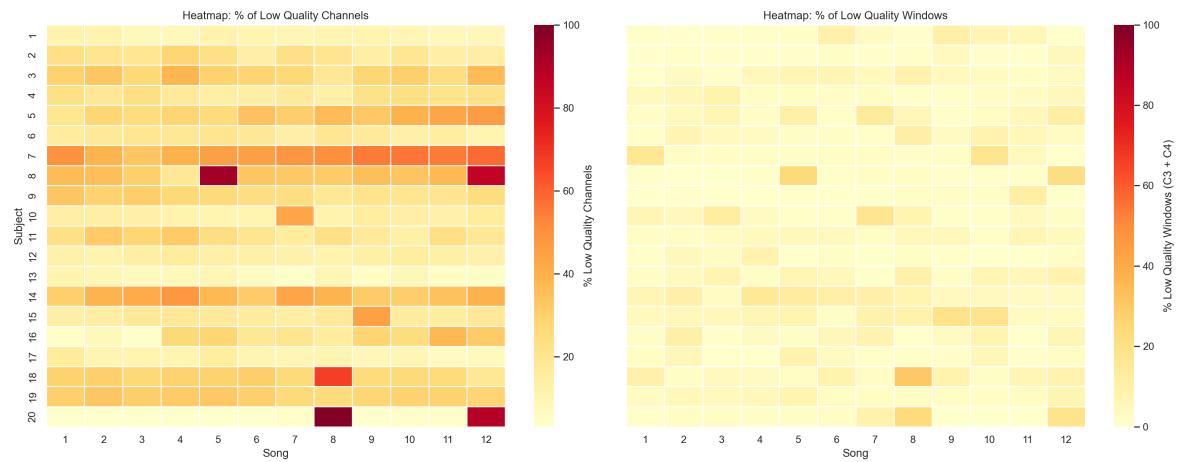
- [36] Giovanni Di Liberto, Claire Pelofi, Roberta Bianco, Prachi Patel, Ashesh D Mehta, Jose L Herrero, Alain de Cheveigné, Shihab A Shamme, and Nima Mesgarani. Cortical encoding of melodic expectations in human temporal cortex, 2019.
- [37] Blair Kaneshiro, Duc T. Nguyen, Anthony M. Norcia, Jacek P. Dmochowski, and Jonathan Berger. Naturalistic music eeg dataset - elgar (nmed-e). <https://purl.stanford.edu/pp371jh5722>, 2021. Available at: <https://purl.stanford.edu/pp371jh5722>.
- [38] Stylianos Bakas, Dimitrios A Adamos, and Nikolaos Laskaris. On the estimate of music appraisal from surface EEG: a dynamic-network approach based on cross-sensor PAC measurements. *J. Neural Eng.*, 18(4):046073, June 2021.
- [39] Isaac Ariza Cervera. EEG database for musical genres detection, January 2025. Title of the publication associated with this dataset: Datasets.

## **Anexo A.**

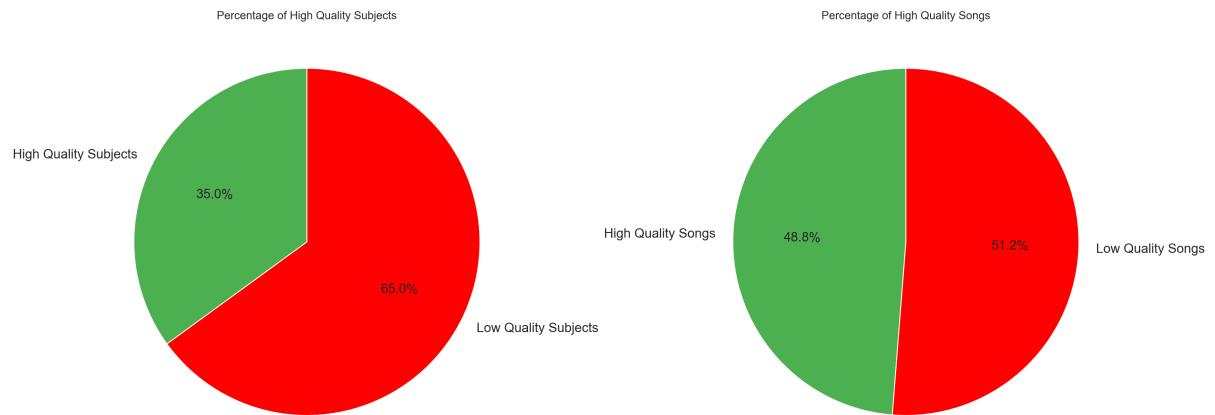
Repositorio GitHub con el código desarrollado: [https://github.com/alr00-hub/Iniciacion\\_Investigacion](https://github.com/alr00-hub/Iniciacion_Investigacion)

## **Anexo B.**

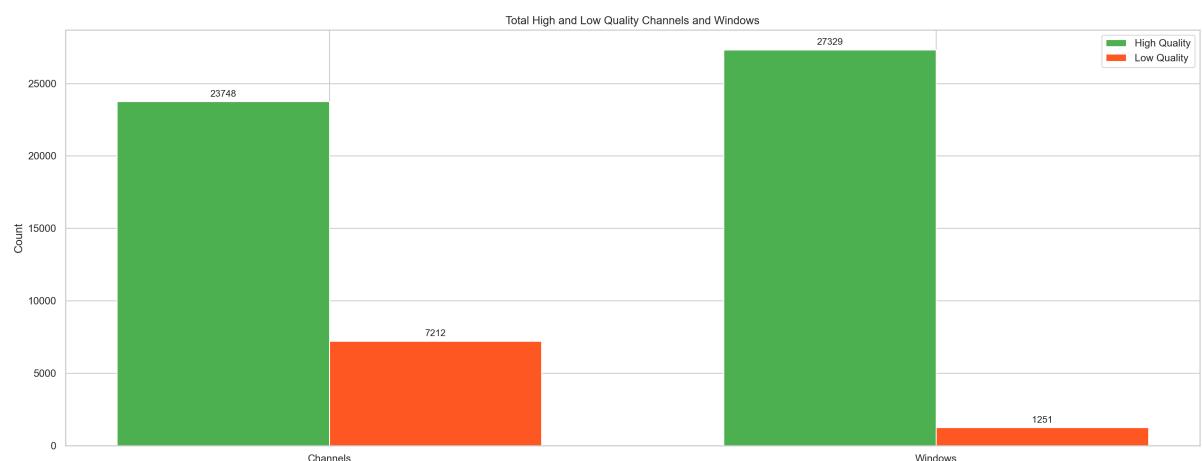
Gráficas finales con los resultados obtenidos por cada conjunto de datos por separado.



(a) Mapas de calor

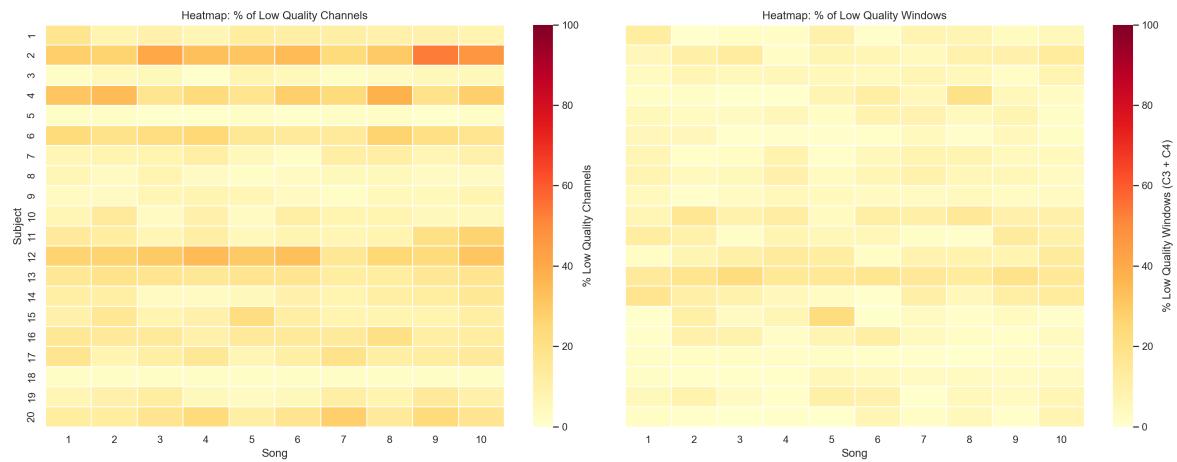


(b) Gráfico circular

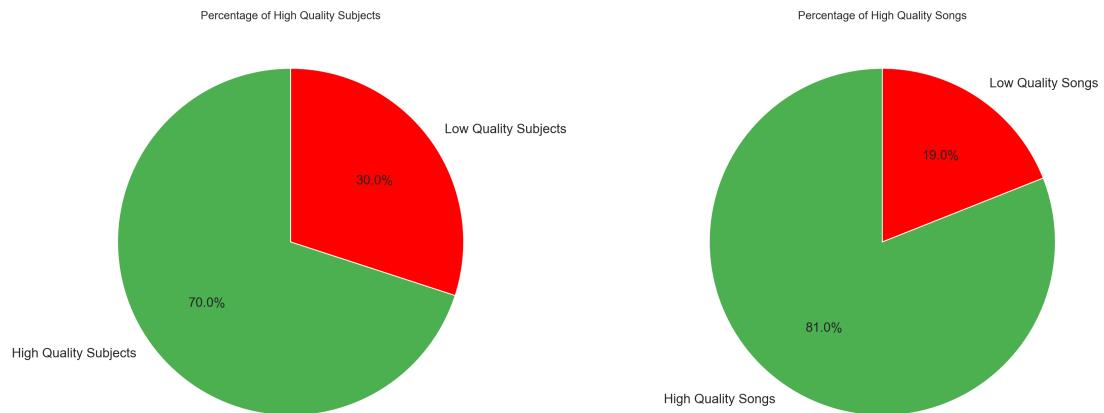


(c) Gráfico de barras

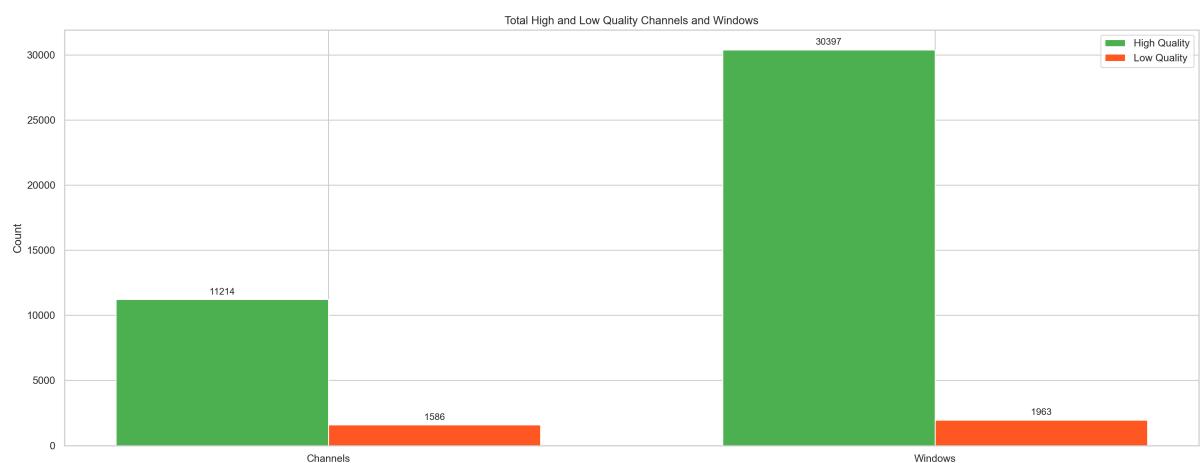
Figura 8: Resultados generales para dsMUSING.



(a) Mapas de calor

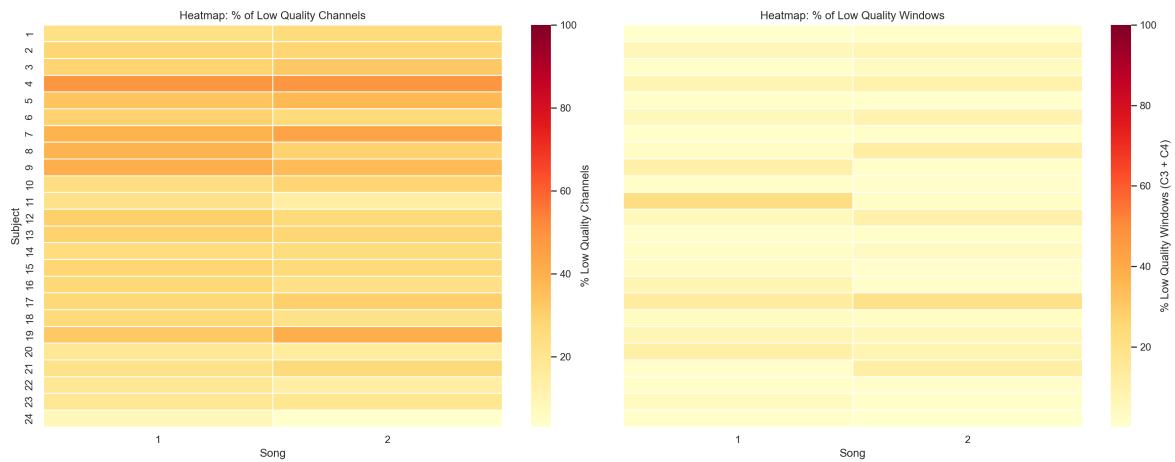


(b) Gráfico circular

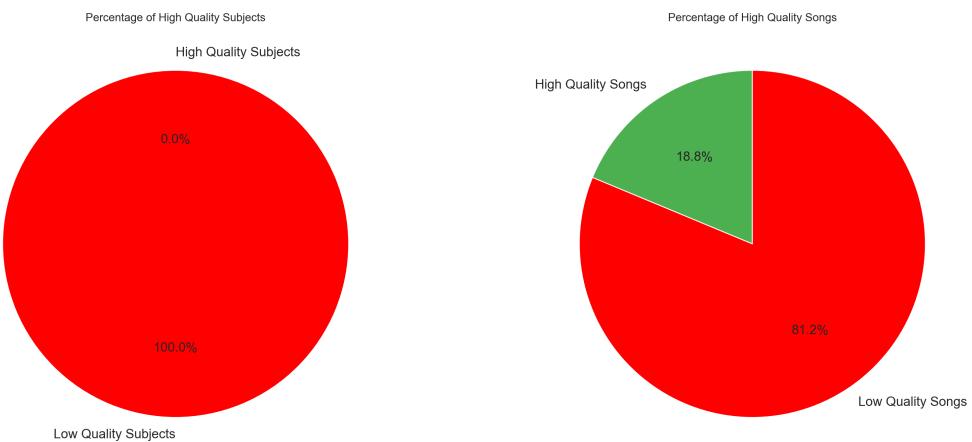


(c) Gráfico de barras

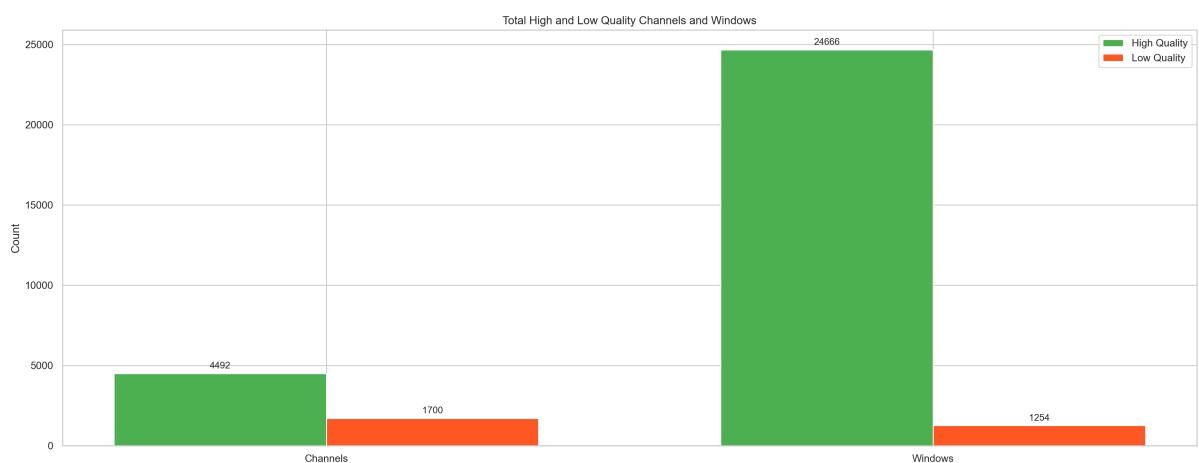
Figura 9: Resultados generales para dsDRYAD.



(a) Mapas de calor

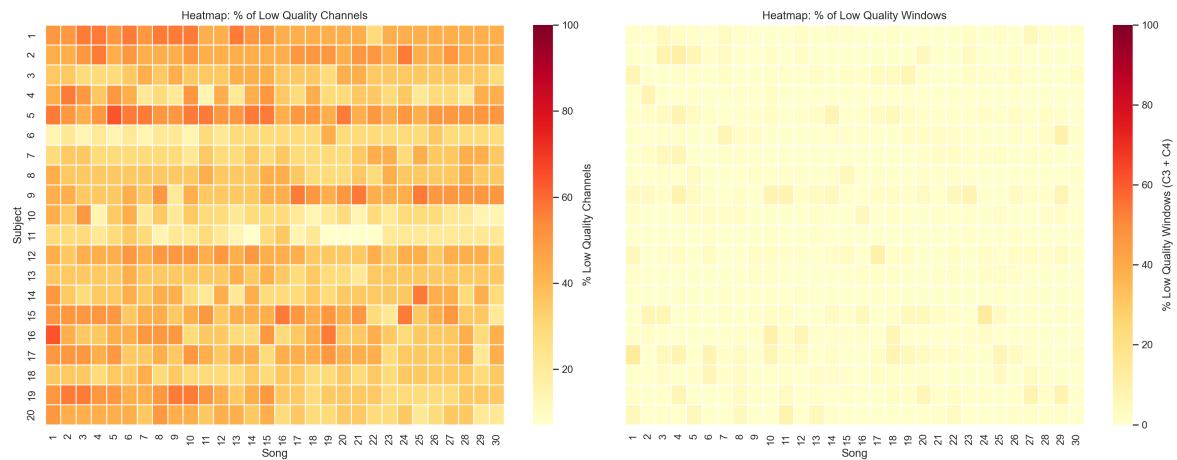


(b) Gráfico circular

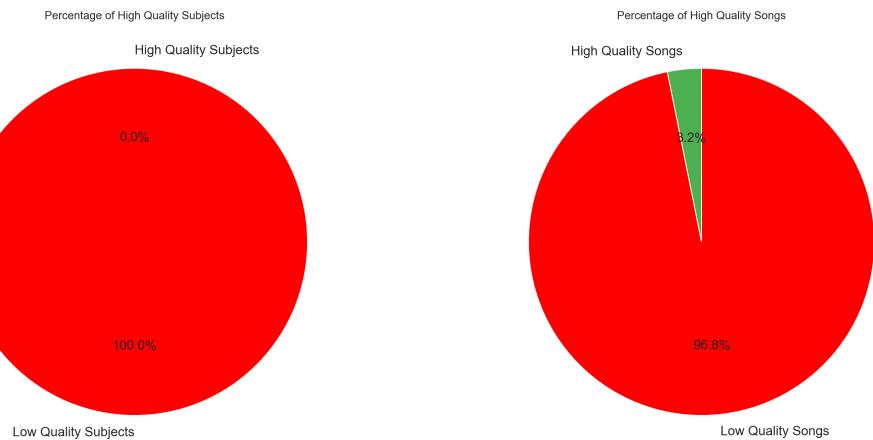


(c) Gráfico de barras

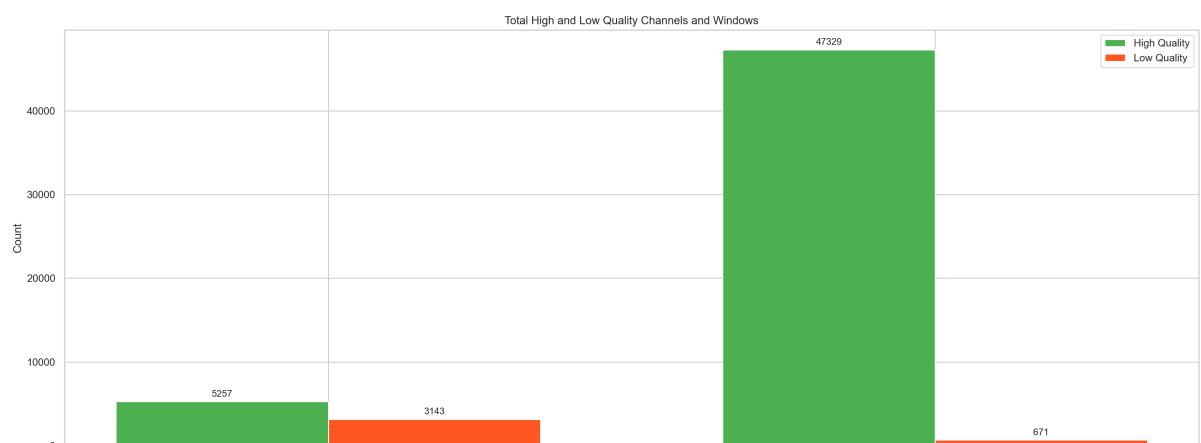
Figura 10: Resultados generales para dsNMEDE.



(a) Mapas de calor

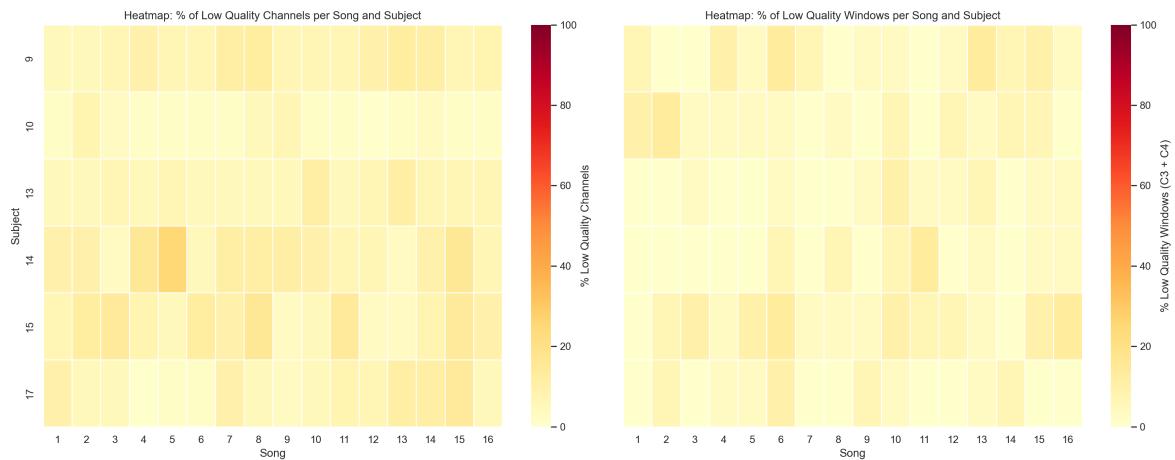


(b) Gráfico circular



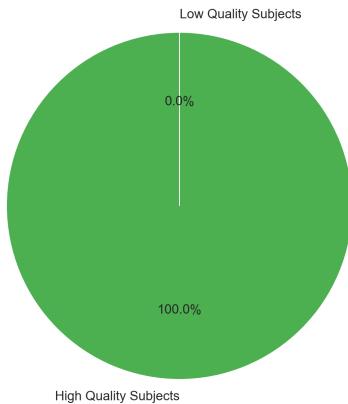
(c) Gráfico de barras

Figura 11: Resultados generales para dsAUTH.

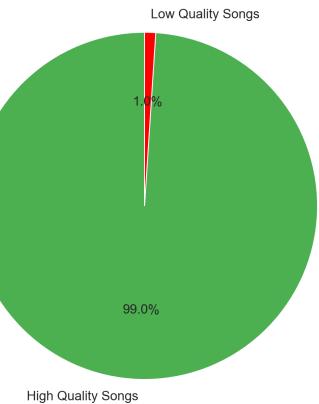


(a) Mapas de calor

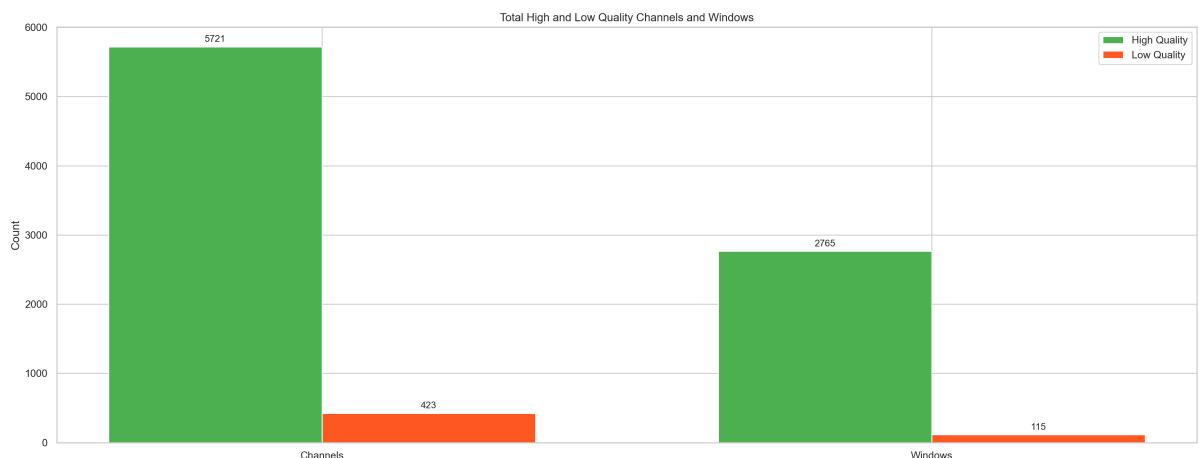
Percentage of High Quality Subjects (> 80% High Quality Songs)



Percentage of High Quality Songs (> 80% usable channels)



(b) Gráfico circular



(c) Gráfico de barras

Figura 12: Resultados generales para dsRIUMA.